

---

# MODELOS, TÉCNICAS E PESQUISA

Curso de Formação de Auditor na ISO | IEC 42.001



Facilitador  
Paulo Carvalho  
Chief Artificial Intelligence Officer

# Inteligência Artificial 2030

A Inteligência Artificial avança em ritmo acelerado, com modelos cada vez mais acessíveis e potentes, exigindo das organizações uma resposta estratégica e adaptativa. Para o Auditor Interno, isso significa a necessidade urgente de **manter-se atualizado sobre as aplicações atuais e emergentes de IA**, compreendendo não só os riscos, mas também o potencial de uso ético e eficaz desses sistemas. A norma ISO/IEC 42001:2024 oferece diretrizes essenciais para estruturar essa governança com foco em segurança, transparência e responsabilidade. Em um cenário de convergência tecnológica, onde IA, biotecnologia e dispositivos conectados se integram, auditar sem esse entendimento é ignorar o contexto real da operação. Assim, o domínio da governança algorítmica torna-se vital para assegurar o uso confiável, sustentável e centrado no ser humano da inteligência artificial.



Paulo Carvalho

---

# Quais organizações irão prosperar

IA 2030 - Tendências

2023

A velocidade é a nova escala

A IA acelera decisões e favorece quem alia velocidade à boa governança e gestão estratégica.

Seus concorrentes não vão esperar

A adoção da IA no seu setor já está gerando ganhos expressivos, e adaptar-se agora é crucial para evitar perdas futuras de competitividade.

O Middle Office está derretendo

A IA está eliminando a necessidade de coordenação manual, e organizações que não se adaptarem terão estruturas lentas e não competitivas.

A Guerra dos Talentos Tem Novas Regras

Atrair e reter talentos de alto desempenho depende cada vez mais da capacidade da organização de adotar ferramentas de IA que ampliem seu impacto

Um imposto oculto sobre a IA

O verdadeiro custo da IA está em ampliá-la, e quem demora a agir pagará cada vez mais caro pela transformação digital.

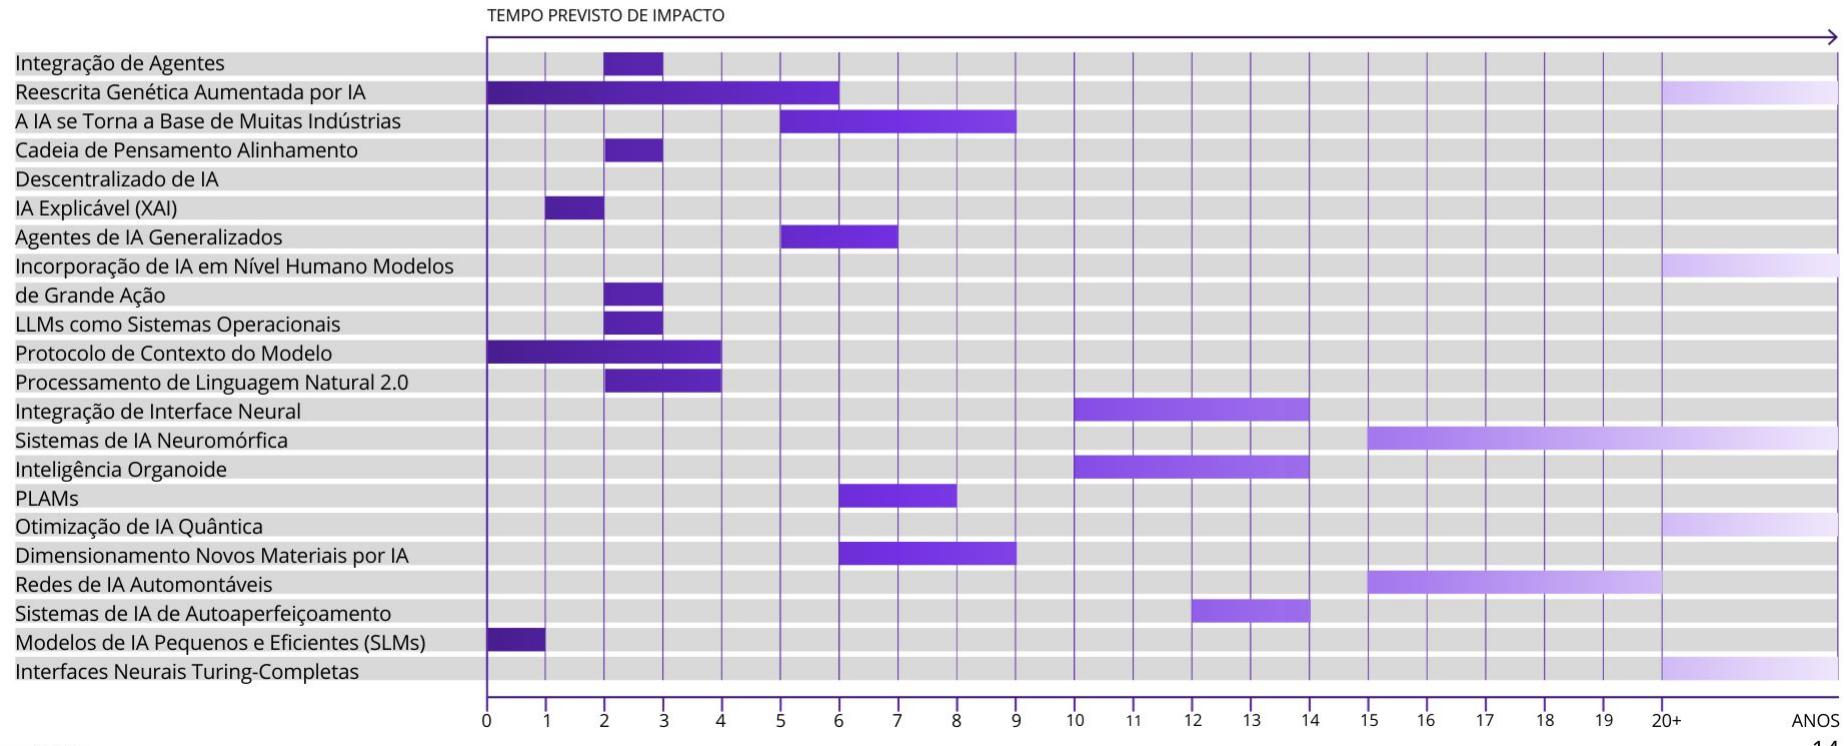
Sua interface está custando clientes

A linguagem natural está substituindo interfaces tradicionais, e quem não se adaptar ficará obsoleto em um mundo cada vez mais conversacional.

Escalar para fora em vez de escalar para cima

A IA está seguindo o caminho da democratização tecnológica, e empresas lentas correm o risco de serem superadas por novatos mais ágeis e eficientes.

As tecnologias generativas avançam nos próximos anos, enquanto métodos de computação como computação organoide e neuromórfica impulsionam desenvolvimentos a longo prazo.



---

# Desenvolvimento de alto nível e curto prazo

IA 2030 - Disrupção

## ESCALAÇÃO

A personalização profunda por IA depende do acesso a grandes volumes de dados, mas sistemas fechados e regulações ainda limitam esse potencial.

## INVESTIMENTO

O avanço da IA depende do equilíbrio entre investimento em P&D e retorno comercial, moldado pela paciência e visão dos investidores.

## RESTRIÇÕES À ADOÇÃO

Mesmo tecnologias maduras enfrentam barreiras culturais e estratégicas que limitam seu impacto, especialmente em setores tradicionais como saúde, seguros e finanças.

## REGULAMENTOS

O avanço da IA tem superado a regulação, e a adoção dependerá de como as normas locais se alinham ou entram em conflito entre si.

## MENÇÕES NA MÍDIA

O entusiasmo popular e a cobertura da mídia podem acelerar a adoção da IA, mesmo sem avanços técnicos significativos.

## PERCEPÇÃO PÚBLICA

A percepção pública sobre a IA moldará sua demanda, especialmente em áreas sensíveis como educação, criatividade, propriedade intelectual e desinformação.

## DESENVOLVIMENTOS DE P&amp;D

Descobertas em IA são imprevisíveis e dependem de fatores como financiamento e equipe, sendo tratadas como variáveis críticas mas incertas no planejamento estratégico.

---

# Desenvolvimento de alto nível e curto prazo

IA 20230 - Termos

**AGENTE IA**

Agentes de IA são entidades autônomas que percebem o ambiente, tomam decisões e agem para alcançar objetivos, variando de automações simples a sistemas multimodais avançados.

**AGI (INTELIGÊNCIA GERAL ARTIFICIAL)**

AGI refere-se a sistemas de IA com capacidades cognitivas iguais ou superiores às humanas em todas as tarefas valiosas, ainda teórica, mas com profundas implicações para trabalho, governança e segurança global.

**ÉTICA DA IA**

A ética da IA é um campo multidisciplinar que analisa os riscos sociais, econômicos e éticos da tecnologia, guiando políticas e regulamentações para alinhar a IA aos valores humanos.

**GOVERNANÇA DE IA**

A governança de IA engloba sistemas e políticas que regulam seu desenvolvimento e uso, sendo essencial para mitigar riscos, promover concorrência justa e lidar com tensões geopolíticas.

**ALGORITMO**

Algoritmos são conjuntos estruturados de regras usados em IA para processar dados, gerar insights e tomar decisões de forma automatizada.

**ALINHAMENTO**

O alinhamento de IA é o processo de garantir que suas decisões e comportamentos refletem intenções humanas, princípios éticos e normas, prevenindo efeitos indesejados ou prejudiciais.

**SUPERINTELIGÊNCIA ARTIFICIAL (ASI)**

A Superinteligência Artificial (ASI) é um conceito hipotético de IA que supera a inteligência humana em todos os domínios, levantando sérios desafios de controle, governança e riscos existenciais.

**RECONHECIMENTO AUTOMÁTICO DE FALA (ASR)**

O Reconhecimento Automático de Fala (ASR) é um sistema de IA que converte fala em texto, viabilizando assistentes virtuais, transcrições e interfaces de voz em diversos aplicativos.

**IA AUTÔNOMA**

A IA autônoma toma decisões e executa tarefas sem intervenção humana, sendo vital em áreas como robótica e segurança, e exigindo fortes salvaguardas para seu uso responsável.

### RACIOCÍNIO EM CADEIA DE PENSAMENTO (COT)

O raciocínio em cadeia é um método de IA que resolve problemas passo a passo, imitando a lógica humana, e aprimora decisões em áreas como matemática, direito e medicina.

### VISÃO COMPUTACIONAL

A visão computacional é uma tecnologia de IA que interpreta imagens e vídeos, sendo aplicada em segurança, automação, medicina e veículos autônomos.

### IA DE BORDA

A IA de ponta executa modelos diretamente em dispositivos como smartphones e sensores, oferecendo processamento em tempo real, menor latência e maior privacidade dos dados.

### MODELO

Modelos de IA são sistemas treinados para analisar dados, fazer previsões e automatizar decisões, variando de regressões simples a redes neurais profundas complexas.

### IA GENERATIVA (GERAL)

A IA generativa cria novos conteúdos como texto, imagens e vídeos, revolucionando setores criativos e de serviços, mas também levantando questões sobre direitos autorais e desinformação.

### GPU (UNIDADE DE PROCESSAMENTO GRÁFICO)

GPUs são hardwares especializados em computação paralela, fundamentais para acelerar o treinamento de modelos de IA e executar tarefas intensivas em dados em larga escala.

### MODELO DE FUNDAÇÃO

Modelos de IA em larga escala, pré-treinados em grandes volumes de dados e adaptáveis a diversas tarefas, servindo de alicerce para aplicações como IA generativa e automação.

### IA MULTIMODAL

A IA multimodal integra diferentes tipos de dados, como texto, imagem e áudio, para melhorar a compreensão e decisões, impulsionando assistentes virtuais, chatbots e diagnósticos médicos.

### PROCESSAMENTO DE LINGUAGEM NATURAL (PLN)

O Processamento de Linguagem Natural (PLN) permite que máquinas compreendam e gerem linguagem humana, sendo usado em chatbots, traduções, análise de sentimentos e moderação de conteúdo.

**PESQUISA DE ARQUITETURA NEURAL (NAS)**

A Otimização Neural Automatizada (AutoML) é um método de IA que ajusta automaticamente arquiteturas de redes neurais, aumentando o desempenho e minimizando a intervenção humana.

**PARÂMETRO**

Parâmetros são variáveis ajustadas durante o treinamento de um modelo de IA para melhorar sua precisão, sendo que grandes modelos podem conter bilhões deles, exigindo alto poder computacional.

**ENGENHARIA DE PROMPT**

A engenharia de prompts consiste em criar entradas estratégicas(PROMPTS) para orientar modelos de IA, sendo essencial para maximizar a eficácia da IA generativa em aplicações comerciais e criativas.

**QUANTUM IA**

A IA quântica combina computação quântica com inteligência artificial, prometendo acelerar o aprendizado de máquina e transformar áreas como criptografia, ciência dos materiais e otimização.

**SISTEMAS DE RECOMENDAÇÃO**

Algoritmos de recomendação usam IA para analisar o comportamento do usuário e sugerir conteúdos, produtos ou serviços, sendo amplamente aplicados em e-commerce, streaming e publicidade digital.

**APRENDIZAGEM POR REFORÇO A PARTIR DO FEEDBACK HUMANO (RLHF)**

O Aprendizado com Feedback Humano (RLHF) é um método de treino em que modelos de IA são ajustados com base em avaliações humanas, aprimorando precisão, alinhamento ético e aplicabilidade prática.

**APRENDIZAGEM AUTO-SUPERVISADA**

O aprendizado não supervisionado é uma abordagem de machine learning em que modelos identificam padrões em dados não rotulados, reduzindo a dependência de anotações humanas.

**APRENDIZAGEM SUPERVISIONADA**

O aprendizado supervisionado é um método em que modelos de IA são treinados com dados rotulados, utilizando pares de entrada e saída para aprimorar a precisão em previsões futuras.

**IA SIMBÓLICA**

A IA simbólica é uma abordagem que representa o conhecimento com símbolos e regras lógicas, permitindo raciocínio explicável e sendo comum em sistemas especialistas.

### DADOS SINTÉTICOS

Dados sintéticos são gerados artificialmente para treinar IA quando dados reais são limitados, tendenciosos ou sensíveis, ajudando a melhorar o desempenho e reduzir riscos de privacidade.

### DADOS DE TREINAMENTO

Os dados de treinamento são usados para ensinar modelos de IA a identificar padrões e fazer previsões, sendo que sua qualidade e diversidade afetam diretamente a precisão e imparcialidade do modelo.

### IA CONFIÁVEL

A IA confiável é projetada com foco em transparência, justiça, responsabilidade e segurança, visando promover a confiança pública e atender às exigências regulatórias.

### APRENDIZAGEM NÃO SUPERVISIONADA

O aprendizado não supervisionado permite que modelos de IA identifiquem padrões e estruturas em dados não rotulados, sendo usado em tarefas como agrupamento e detecção de anomalias.

### XAI (IA EXPLICÁVEL)

A IA explicável é desenvolvida para oferecer decisões transparentes e compreensíveis, promovendo confiança e responsabilidade em setores críticos como saúde e finanças.

### APRENDIZAGEM ZERO-SHOT (ZSL)

O aprendizado zero-shot permite que modelos de IA apliquem conhecimentos prévios para realizar tarefas inéditas sem treinamento específico, sendo usado em tradução automática e reconhecimento de imagens.

---

# Modelos, Técnicas e Pesquisa

IA 2030 -

Os modelos de IA exigem grandes volumes de dados e recursos de computação para desbloquear seu potencial transformador (ou assim pensávamos).

## Expansão das modalidades de IA generativa

### Modelos

IA multimodal amadureceu e começou a transformar aplicações reais, permitindo que sistemas como o GPT-4o e Claude 3 integrem texto, imagem e som para resolver tarefas complexas com fluidez e precisão — marcando uma nova era de interação conversacional entre humanos e máquinas.

### Termos

IA multimodal é um tipo de inteligência artificial que **entende e combina diferentes tipos de informação ao mesmo tempo**, como texto, imagem, áudio e vídeo.

Por exemplo: você pode **mostrar uma foto, falar algo e escrever uma pergunta**, e a IA entende tudo junto para te dar uma resposta mais completa — como se fosse uma pessoa ouvindo, lendo e vendo ao mesmo tempo.

É o que permite, por exemplo:

- Tirar foto de uma receita e pedir para ajustar as porções.
- Mostrar uma imagem médica e pedir uma explicação.
- Falar com um assistente virtual usando voz e imagem.

Ela está tornando a interação com máquinas **mais natural e inteligente**, quase como conversar com alguém que entende vários sentidos ao mesmo tempo.

## Afinação

### Modelos

O ajuste fino de modelos de linguagem se tornou uma ferramenta estratégica, permitindo personalização precisa, redução de custos e democratização do acesso a LLMs, com aplicações que vão da biotecnologia à conformidade regulatória em setores como saúde e finanças.

### Termos

**Ajuste fino de IA** é como **ensinar uma IA que já sabe muito a se especializar em algo específico**.

Imagine que a IA é como um aluno que já leu milhares de livros sobre tudo (como medicina, direito, culinária, tecnologia...). Com o ajuste fino, você pega esse aluno e o treina só com **os assuntos que interessam pra sua empresa, setor ou necessidade**.

Por exemplo:

- Um hospital pode ajustar a IA para entender termos médicos e ajudar em diagnósticos.
- Uma empresa pode treiná-la com seus produtos e jeitos de falar, pra melhorar o atendimento ao cliente.

Isso deixa a IA **mais esperta, personalizada e útil para tarefas específicas**, sem precisar criar tudo do zero — economizando tempo e dinheiro.e regulatória em setores como saúde e finanças.

## Aprendizagem de reforço automatizada

### Modelos

O DeepSeek demonstrou que é possível treinar IA de alto desempenho com **feedback automatizado de computador**, reduzindo custos e tempo em tarefas com respostas objetivas, como matemática e codificação, embora o feedback humano ainda seja essencial em atividades mais subjetivas.

### Termos

**Aprendizagem de reforço automatizada** é uma forma de ensinar a inteligência artificial (IA) **por tentativa e erro, com a ajuda de um computador, sem precisar de humanos o tempo todo**.

Pense assim: a IA faz uma tarefa (como resolver um problema ou jogar um jogo), e o computador dá uma “recompensa” ou uma “punição” dependendo se a resposta foi certa ou errada. Com isso, **a IA vai aprendendo sozinha o melhor caminho**, como se estivesse jogando um jogo em que precisa descobrir a melhor estratégia.

Antes, esse tipo de aprendizado dependia de pessoas avaliando as respostas da IA. Agora, com a **aprendizagem de reforço automatizada**, o próprio sistema avalia e ensina, o que **economiza tempo, dinheiro e acelera o aprendizado**, especialmente em tarefas com respostas claras, como matemática ou programação

## Composição Evolutiva

### Técnica

A Sakana AI propõe um novo caminho para IA avançada ao combinar modelos existentes com algoritmos evolucionários, evitando a necessidade de treinar sistemas massivos do zero. Essa abordagem torna o desenvolvimento de IA mais acessível, eficiente e sustentável, inspirando-se na complexidade da natureza.

### Termos

**Composição Evolutiva de IA** é como **montar um supertime de diferentes inteligências artificiais já existentes**, combinando as melhores partes de cada uma — e deixando que o próprio sistema descubra, sozinho, **qual é a melhor forma de juntá-las**, usando ideias inspiradas na evolução da natureza.

**Em vez de:** Treinar um modelo gigante do zero (caro e demorado) Fazemos a IA aprender **como combinar modelos menores que já sabem fazer coisas diferentes** — como entender textos, ver imagens ou resolver contas

**Exemplo prático (bem simples):**

Imagine que você tem:

- Uma IA que entende **japonês perfeitamente**
- Outra que é ótima em **resolver problemas de matemática**
- E outra que entende **cultura e expressões locais**

A **composição evolutiva** tenta várias combinações dessas IAs, como se fosse testando diferentes receitas, até descobrir uma que junte o melhor de todas — criando um novo modelo que **fala japonês, resolve contas e entende o contexto cultural** melhor do que qualquer uma sozinha.

**Pense nisso como montar um time ideal:** você não precisa que cada jogador seja perfeito em tudo, mas sim combinar habilidades diferentes para um desempenho excelente em conjunto!

## Mistura de especialistas

### Técnica

A técnica de Mistura de Especialistas (MoE) divide um modelo em submodelos especializados, com um mecanismo que direciona cada tarefa ao “especialista” mais adequado, tornando a IA mais eficiente. A DeepSeek usou MoE para criar um sistema tipo ChatGPT a um custo bem menor, chamando atenção para essa abordagem. MoE permite escalar IA com desempenho elevado e menos exigência de hardware caro.

É como montar **uma equipe de especialistas** dentro de um único sistema de IA. Cada parte do sistema é treinada para ser muito boa em uma coisa específica — como matemática, escrita ou análise de imagem — e tem **um “gerente” que escolhe quem faz o quê** dependendo da tarefa recebida.

Imagine que você tem uma escola virtual com:

- Um professor de **matemática**
- Uma professora de **português**
- Um instrutor de **arte**
- E um coordenador que **sabe qual professor deve responder cada pergunta**.

Se um aluno perguntar:

- “Quanto é  $12 \times 9$ ?” → o coordenador chama o **professor de matemática**.
- “Corrija meu texto de redação.” → ele chama a **professora de português**.
- “Me ajude a desenhar um logotipo.” → ele chama o **instrutor de arte**.

### Termos

Esse é o jeito que a **IA MoE trabalha**:

**Elas não tentam fazer tudo com um único modelo gigante, mas escolhem o melhor “especialista” para cada tarefa** — o que economiza energia, melhora a resposta e reduz custos.

## Autonomia dos Especialistas

### Pesquisa

Pesquisadores propuseram uma evolução do MoE chamada **Autonomia de Especialistas (AoE)**, onde os próprios especialistas decidem se devem responder a uma entrada. Diferente do MoE tradicional, essa abordagem **dispensa o roteador central** e usa os sinais internos dos especialistas para guiar a escolha. Isso torna o sistema mais ágil e potencialmente mais eficiente.

### Termos

É uma nova forma de organizar a inteligência artificial como **uma equipe de especialistas que se autogerencia**, sem precisar de um “chefe” para dizer quem faz o quê.

#### Como assim?

Em vez de ter um coordenador (como no MoE) dizendo:

“Você responde essa pergunta, você faz aquela”,

no AoE, **cada especialista lê a pergunta e decide sozinho se pode responder ou não.**

Se a IA de matemática sentir que a pergunta é sobre números, ela mesma levanta a mão e diz “essa é comigo!”. Se não for, ela se cala — simples assim

#### Exemplo prático:

Imagine que você tem uma IA com vários especialistas:

Um entende de **comida**, outro de **música**, outro de **viagens**. Você pergunta:

*“Qual a melhor época para visitar o Japão?”*

Cada especialista “escaneia” a pergunta.

A IA de comida pensa: “Não é comigo.”

A IA de música ignora.

Mas a IA de viagens diz: “Sim! Isso eu sei responder.” Ela responde diretamente, **sem precisar que um coordenador escolha por ela.**

## LLMs como sistemas operacionais

### Pesquisa

Um novo tipo de sistema operacional, como o AIOS, usa um modelo de linguagem grande (LLM) como seu núcleo, permitindo que os usuários interajam por linguagem natural em vez de comandos técnicos. Esse sistema automatiza tarefas com inteligência, tornando o uso do computador mais intuitivo e eficiente. O LLM também gerencia decisões, recursos e agentes simultâneos, criando uma experiência computacional mais adaptável.

### Termos

Tradicionalmente, um **sistema operacional** (como Windows, macOS ou Linux) serve para **controlar tudo o que acontece no seu computador** — arquivos, programas, memória, etc. Mas você precisa clicar, arrastar, abrir janelas ou digitar comandos para fazer o que quer.

Agora imagine que no lugar disso, você **simplesmente conversa com o computador**, como se estivesse falando com um assistente muito inteligente.

Isso é possível com os **LLMs (Modelos de Linguagem de Grande Escala)** sendo o “cérebro” principal do sistema operacional.

### Exemplo prático:

Você liga seu computador e diz:

☞ “Organize todos os meus arquivos por tipo e envie os PDFs importantes para o e-mail do João.”

➡ O sistema entende, localiza os arquivos certos, organiza as pastas, envia o e-mail e te avisa quando terminar — **sem você clicar em nada**.

Ou ainda:

☞ “Me avise quando tiver uma reunião e prepare uma apresentação com os dados do último relatório.”

➡ O computador busca os dados, cria os slides e te avisa na hora da reunião.

## LLMs: Maiores e mais caros

### Pesquisa

Os LLMs cresceram com base na ideia de que “maior é melhor”, trazendo avanços, mas também custos altíssimos e desafios de eficiência. Estudos recentes mostram que o aumento do tamanho nem sempre gera ganhos proporcionais em desempenho. Agora, o foco está mudando para modelos menores, mais eficientes e especializados, adaptados às necessidades reais das empresas.

### Termos

Durante anos, acreditava-se que **quanto maior o modelo de IA, melhor o desempenho**. E de fato, modelos como o **GPT-4** (da OpenAI) e o **Gemini** (do Google) ficaram incríveis — mas também **caríssimos de treinar**. Só o GPT-4 custou mais de **78 milhões de dólares!** E isso exige **muito hardware, energia e dinheiro**.

Mas agora os pesquisadores estão percebendo que:

👉 Nem toda tarefa precisa de um modelo gigante.

👉 Às vezes, **modelos menores e bem ajustados funcionam melhor e custam menos**.

👉 Modelos enormes podem ter “retorno decrescente” — ou seja, crescem, mas não melhoram tanto assim.



### Exemplo prático (vida real):

Imagine uma empresa que precisa de uma IA só para **responder dúvidas sobre seus produtos**.

Ela não precisa de um modelo do tamanho do GPT-4, que sabe falar de tudo do mundo.

Ela pode usar um **modelo menor**, treinado apenas com os dados da empresa (ajuste fino), que será:

- Mais barato,
- Mais rápido,
- E até **mais preciso**, porque só foca no que é importante pra ela.

## Modelos de cadeia de pensamento

### Modelos

Com os limites do crescimento de modelos gigantes, a atenção se volta para abordagens como a Cadeia de Pensamento (CoT), que foca em raciocínio estruturado em tempo real. Modelos como o1 e R1 mostram que gerar etapas lógicas internas melhora a precisão, mesmo que exija mais computação durante o uso. Isso marca uma mudança do foco no pré-treinamento para a eficiência e inteligência na hora da inferência.

### Termos

Antes, a ideia era simples:

**“Quanto maior o modelo de IA, melhor.”**

Ou seja, mais dados, mais memória, mais poder de processamento = melhores respostas.

Mas isso ficou **caro, demorado e com pouco ganho em alguns casos.**

Agora surgiu uma nova abordagem chamada **Cadeia de Pensamento (Chain of Thought, ou CoT)**.

Ela funciona assim: em vez de tentar acertar a resposta direto, a IA **pensa em etapas**, como se estivesse **resolvendo um problema passo a passo em voz alta**, igual a um ser humano.



### Exemplo prático (bem simples):

Suponha que você pergunte para a IA:

Q “Se João tem 12 maçãs e dá 4 para Maria, quantas ele tem?”

- Um modelo antigo tentaria responder direto: “8”
- Um modelo com **Cadeia de Pensamento (CoT)** faz assim:

🧠 “João começou com 12 maçãs. Ele deu 4 para Maria. 12 menos 4 é 8. Então ele ficou com 8.”

➡ **Elá pensa antes de responder, checa o raciocínio**, e por isso, erra menos — principalmente em perguntas difíceis ou confusas.

## Pequeños modelos de linguagem

### Modelos

Pequenos modelos de linguagem (SLMs) estão mostrando que é possível obter alto desempenho com muito menos recursos, superando modelos maiores em tarefas específicas com mais eficiência e menor custo. Exemplos como o GPT-4o mini, Phi-3-mini e OpenELM provam que modelos compactos podem operar em dispositivos locais, garantindo privacidade e rapidez. A tendência aponta para uma IA mais acessível, personalizada e modular, com múltiplos modelos especializados atuando em conjunto.

Por muito tempo, acreditava-se que **só modelos gigantes de IA** (como o ChatGPT-4) eram bons.

Mas agora, os **modelos pequenos de linguagem (SLMs)** estão provando que podem fazer **coisas muito bem — e gastando muito menos!**

### Por que isso importa?

1. **Mais barato** – As empresas não precisam investir em supercomputadores.
2. **Mais rápido** – Respostas imediatas, direto no seu dispositivo.
3. **Mais seguro** – Seus dados não saem do aparelho (privacidade!).
4. **Mais personalizado** – A IA pode ser treinada para **tarefas específicas**, como agricultura, manufatura ou saúde, sem precisar ser um modelo gigante que sabe “tudo do mundo”.

### Termos



### Exemplo prático (vida real):

Imagine que você tem um **smartphone**.

Antes, para usar IA poderosa, seu celular precisava **mandar tudo para a nuvem** (internet), esperar o processamento, e então receber a resposta. Isso gasta tempo, internet e energia.

Agora, com **SLMs**, a IA pode rodar **direto no celular**, sem depender da nuvem!

Você pode:

- Traduzir textos,
- Organizar sua agenda,
- Criar respostas automáticas para e-mails

→ **Tudo com rapidez, privacidade e sem esgotar a bateria.**

## Aterramento e Aumento de Contexto

### Modelos

O NotebookLM do Google usa IA para oferecer respostas personalizadas e confiáveis, conectando-se diretamente aos seus documentos e fontes. Com técnicas como aterramento e aumento contextual, ele reduz erros e melhora a relevância das respostas. Essa abordagem está transformando a IA em uma ferramenta precisa e adaptável para uso pessoal e empresarial.

### Termos

## O que é o NotebookLM do Google?

É uma ferramenta de IA que funciona como **um assistente de estudos ou de trabalho**, só que **inteligente e personalizado**.

Diferente de chatbots genéricos, o NotebookLM **lê seus documentos do Google Docs**, entende o conteúdo e **responde perguntas com base no que você escreveu**.

### Por que isso é útil?

1. **Evita informações erradas (alucinações)** – A IA só responde com base no que você já escreveu ou carregou.
2. **Poupa tempo** – Em vez de procurar manualmente nos documentos, a IA **sintetiza tudo pra você**.
3. **Ajuda a conectar ideias** – Ele cruza dados de diferentes fontes para **te dar insights mais inteligentes**.

### Exemplo prático (vida real):

Imagine que você está preparando um **TCC, relatório ou planejamento estratégico**.

Você já tem um monte de anotações espalhadas em documentos diferentes.

Com o **NotebookLM**, você pode perguntar:

“*Quais foram os principais pontos da reunião de abril sobre marketing digital?*”

→ E ele vai **buscar essa informação diretamente nas suas anotações**, e ainda dizer de qual documento tirou a resposta.

## Superando a escassez de dados

### Modelos

A escassez de dados textuais de alta qualidade ameaça o avanço de grandes modelos de IA, com previsões de esgotamento já em 2026. Para contornar isso, laboratórios estão recorrendo a dados privados, visuais, sintéticos e estratégias como *self-play*, onde modelos treinam contra si mesmos. No entanto, depender demais de dados sintéticos pode prejudicar a diversidade e qualidade dos resultados, exigindo abordagens inovadoras para manter o progresso.

#### O que está acontecendo com os dados usados para treinar IA?

Para treinar uma **inteligência artificial poderosa**, é preciso dar a ela **muito conteúdo de qualidade** — textos, imagens, vídeos... como se fosse a “alimentação” da IA.

Só que temos um problema:

**A internet pública já está ficando sem dados bons para treinar esses modelos** — ou seja, os sites com textos bem escritos e confiáveis estão acabando para esse uso.

Estudos dizem que até **2026**, os dados de boa qualidade da internet podem se esgotar.

Os laboratórios estão **buscando novas formas de ensinar IA**. **Comprar dados privados**, como de jornais ou plataformas educacionais. **Usar dados visuais e de áudio**, como vídeos de YouTube ou gravações para ensinar sobre o mundo real.

### Termos

#### Exemplo prático:

Imagine que você quer ensinar alguém a cozinhar.

Nos primeiros dias, você dá ótimos livros e vídeos de chefs renomados.

Depois de um tempo, só sobram receitas mal escritas, vídeos de baixa qualidade ou até repetidos.

→ A pessoa aprende menos, ou até aprende errado.

Com a IA é igual: **sem conteúdo bom, ela para de evoluir — ou pior, começa a “pirar” nas respostas.**

## IA de código aberto

### Modelos

O lançamento do modelo R1 pela DeepSeek e o avanço de outros modelos abertos como Llama e Mistral mostram que a IA de código aberto está alcançando e até superando soluções proprietárias, com menor custo. Essa tendência é reforçada pelo crescimento explosivo do desenvolvimento colaborativo em plataformas como o GitHub. Paralelamente, a IA modular vem ganhando destaque ao permitir a criação de sistemas mais eficientes, personalizados e escaláveis, combinando módulos especializados para tarefas específicas.

#### O que está acontecendo com a IA de código aberto?

Antes, os modelos de IA mais avançados eram **fechados**, como o ChatGPT ou o Gemini do Google — ninguém podia ver como eram feitos nem usá-los livremente.

Mas agora, empresas como **DeepSeek**, **Meta (Facebook)** e **Mistral** estão lançando modelos **abertos e gratuitos**, que qualquer pessoa pode usar, estudar ou melhorar.

### Termos

Exemplo:

- O modelo **R1 da DeepSeek** é superpoderoso e custa muito menos que modelos como o GPT-4.
- O **Llama da Meta** e o **Mistral da Mistral** já estão sendo usados por empresas como o **Wells Fargo** e o navegador **Brave**.



#### Exemplo prático:

Imagine que você é dono de uma empresa e quer uma IA para ajudar seus clientes.

Antigamente, você teria que **pagar caro** para usar uma IA fechada.

Agora, com esses **modelos de código aberto**, você pode **baixar um modelo gratuito**, treinar com os dados da sua empresa e rodar localmente — **sem depender de grandes plataformas**.

## Grandes modelos de ação

### Pesquisa

Os Modelos de Ação Grande (LAMs) são IAs que não apenas conversam, mas também executam tarefas ativamente em computadores, como clicar, digitar e navegar. Eles representam um passo rumo a sistemas autônomos completos, capazes de agir como usuários humanos em ambientes digitais. Embora promissores, levantam preocupações sobre privacidade, já que precisam de amplo acesso aos dados e sistemas dos usuários.

### Termos

## O que são LAMs (Modelos de Ação Grande)?

Até agora, a maioria das inteligências artificiais (como o ChatGPT) só **responde com texto** — ou seja, **ela conversa, mas não faz nada no seu computador**.

Os **LAMs** são uma nova geração de IA que **não só falam, mas também agem**.

Eles **clicam, digitam, navegam, arrastam arquivos, preenchem formulários** — como se fossem um humano usando o computador por você.

### ⚠️ Mas tem um porém...

Para funcionar assim, a IA precisa **ver sua tela, acessar seus arquivos e comandos**. Isso levanta dúvidas sobre **privacidade e segurança**, pois ela teria acesso a tudo que você faz ou guarda no computador.



### Exemplo real:

O **Claude 3.5 Sonnet**, da Anthropic, já consegue:

- Mover o cursor do mouse
- Clicar em botões
- Ler capturas de tela
- Escrever textos
- Navegar em sistemas de computador

## Modelos de Ação Grande Pessoal

### Pesquisa

Os PLAMs (Modelos de Grande Ação Pessoal) são IAs altamente personalizadas, treinadas com todos os dados da vida digital de uma pessoa, como redes sociais, localização, e-mails e hábitos. Eles seriam capazes de tomar decisões alinhadas ao comportamento e preferências individuais, atuando como uma verdadeira extensão digital do usuário. Embora ainda teóricos, esses modelos prometem transformar a relação entre humanos e IA, criando forte dependência das plataformas que os oferecem.

### Termos

#### O que são PLAMs (Modelos de Grande Ação Pessoal)?

Os **PLAMs** são um tipo de inteligência artificial ainda mais avançada e **muito mais pessoal**.

Diferente de outras IAs que sabem coisas genéricas (como o ChatGPT), um PLAM seria treinado **exclusivamente com os dados da sua vida**.

Ele saberia tudo sobre:

- Suas mensagens, e-mails, calendário 
  - Seu histórico de compras 
  - Onde você está e com quem está 
  - Seus horários, preferências, rotina e até batimentos cardíacos, se você usar smartwatch 
- É como se fosse **um clone digital seu**, que entende você melhor do que qualquer outro sistema.



#### Exemplo prático:

Imagine que você está saindo do trabalho.

Seu PLAM já sabe:

- Que está chovendo 
- Que seu carro está com pouco combustível 
- Que você jantou tarde ontem 
- E que tem uma reunião cedo amanhã 

Ele **automaticamente agenda um delivery leve**, ajusta seu despertador e **programa o GPS para abastecer no caminho mais curto para casa** — tudo sem você pedir.

